

UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

FACULTAD DE CIENCIAS



Tarea 06:  
**Estrategias evolutivas**



*Pablo A. Trinidad Paz - 419004279*

Trabajo presentado como parte del curso de **Cómputo Evolutivo** impartido por el profesor **Mario Iván Jaen Márquez**.

Fecha de entrega: **Jueves 4 de Abril de 2019**.

1. **[Ejercicio de programación]** Escribe una función que genere números pseudo-aleatorios de las distribución normal estándar  $N(0, 1)$  a partir de números uniformemente distribuidos. Indica el método usado.

**Solución:** Se implementó el método de muestreo de números pseudo-aleatorios descrito por Box-Muller<sup>1</sup>. A continuación se presentan los resultados de la implementación comparados con el método `random.gauss(0, 1)` de la librería estándar de Python.



---

<sup>1</sup>[https://en.wikipedia.org/wiki/Box-Muller\\_transform](https://en.wikipedia.org/wiki/Box-Muller_transform)

2. [Ejercicio de programación] Implementa el algoritmo (1+1)-ES. Prueba tu algoritmo sobre la función *Sphere*, la cuál es una función unimodal  $d$ -dimensional definida como:

$$f(\vec{x}) = \sum_{i=1}^d x_i^2$$

Donde cada  $x_i \in [-100, 100]$ . Utiliza un parámetro  $\sigma = 1$  y un punto inicial  $\vec{x} = (x_1, \dots, x_d) = (-99, \dots, -99)$

- a) Ejecuta tu algoritmo para  $d = 10$  y para  $d = 100$ . ¿Qué tan cerca del óptimo converge y qué tan rápido?

**Respuesta:** Para  $d = 10$  con una precisión de 0.01 y un máximo de  $10^6$  iteraciones, el algoritmo concluye después 413 mutaciones exitosas debido a haber alcanzado el número máximo de iteraciones con un valor promedio para cada  $x_i$  de  $-0.068264$  y un fitness de 0.34359 (el cual no cumple con la precisión). Para  $d = 100$  con la misma precisión, el algoritmo concluye después de 1296 mutaciones exitosas con un valor promedio para cada  $x_i$  de 0.03281650 y fitness de 125.16605 (nuevamente lejano al óptimo y terminando debido al número máximo de iteraciones).

- b) Implementa la regla del 1/5 y vuelve a ejecutar tu algoritmo. ¿Qué diferencias observas respecto a la ejecución anterior?

**Respuesta:** La diferencia es fundamental en el sentido de que los algoritmos sí convergieron y en menos iteraciones que el límite permitía ( $10^6$ ). Aproximadamente el  $\sim 20\%$  de las mutaciones fueron exitosas en ambos casos a comparación del caso anterior donde menos del 0.001% de las mutaciones fueron exitosas. En ambos casos se logró obtener fitness bajo la precisión solicitada: para  $d = 10$  se obtuvo 0.00907 y para  $d = 100$  se obtuvo 0.00987 con 515 y 22,867 iteraciones respectivamente y 120 y 5,715 mutaciones exitosas respectivamente.

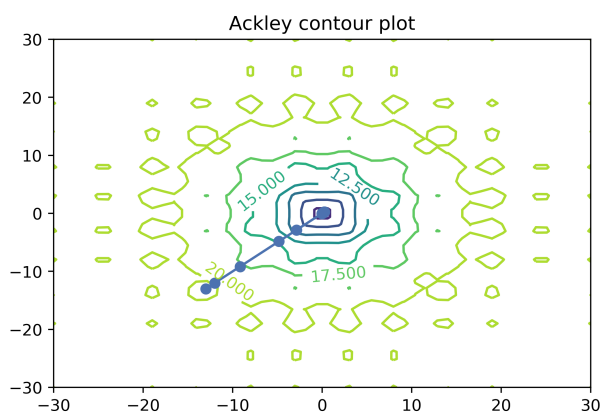

```
Starting simulation with d=10 (fifth rule disabled)
Objective reached
  Generations: 1000000
  Successful mutations: 413
  Chromosome mean: -0.06826455987971958
  Fitness: 0.34359743285720606
Starting simulation with d=100 (fifth rule disabled)
Objective reached
  Generations: 1000000
  Successful mutations: 1296
  Chromosome mean: 0.032816509152443094
  Fitness: 125.16605998855266
Starting simulation with d=10 (fifth rule enabled)
Objective reached
  Generations: 515
  Successful mutations: 120
  Chromosome mean: -0.005919947575676352
  Fitness: 0.009073898608427272
Starting simulation with d=100 (fifth rule enabled)
Objective reached
  Generations: 22867
  Successful mutations: 4715
  Chromosome mean: 0.0003964242388768172
  Fitness: 0.009875960400695284
```

3. **[Ejercicio de programación]** Implementa el algoritmo  $(\mu + \lambda)$ -ES usando mutación no correlacionada (una sola  $\sigma$  para todas las dimensiones del problema). Para adaptar el tamaño de la mutación de  $\sigma$  usa la recomendación dada en clases  $\tau = 1/\sqrt{d}$ . Prueba tu algoritmo en la función *Sphere* y también en la función *Ackley*, definida como:

$$f(\vec{x}) = -20 \cdot \exp \left( -0.2 \cdot \sqrt{\frac{1}{d} \cdot \sum_{i=1}^d x_i^2} \right) - \exp \left( \frac{1}{d} \cdot \sum_{i=1}^d \cos(2\pi x_i) \right) + 20 + \exp(1)$$

donde cada  $x_i \in [-30, 30]$ . Prueba con diferentes valores de  $\mu$  y  $\lambda$  hasta alcanzar convergencia al óptimo global con un error por debajo de 0.001. Puedes usar la recomendación de parámetros  $\frac{\lambda}{\mu} \approx 7$ .

- a) Ejecuta tu algoritmo en  $d = 2$  y grafica los contornos de nivel de la función en los niveles de  $f(x) : 2, 4, 6, 8, 100, 12, 14, 16, 18$  y 20.



b) ¿Qué tan bien funciona  $d = 10$  respecto a la  $(1 + 1)$ -ES?

**Respuesta:** Usando precisión de 0.001 y  $d = 10$ ,  $(\mu + \lambda)$ -ES converge después de 74 generaciones mientras que  $(1 + 1)$ -ES lo hace después de 667 generaciones con únicamente 146 mutaciones exitosas.

```
Starting simulation with d=10 (fifth rule enabled)
Objective reached
  Generations: 667
  Successful mutations: 146
  Chromosome mean: 0.0002929739209432219
  Fitness: 0.0008729120379531627
*****
Starting (mu+lambda) simulation to solve Sphere with 10 dimensions
  Mu=5      Lambda=35
  Max trials=1000000
  Precision=0.001
  Search space=[-30, 30]
Simulation finished!
  Generations: 74
  Best:
    Fitness: 0.0008629828305260569
    Chromosome: 0.0035, 0.0067, -0.0063, -0.0060, 0.0139, -0.0154, -0.0063, 0.0032, -0.0032, -0.0154
```